

ANALISIS EDA, PREPROCESSING, DAN REGRESI LINEAR

**Penerapan Exploratory Data Analysis,
Data Preprocessing, dan Linear
Regression pada Dataset House Prices**

Disusun Oleh: Rifa'ah Fatihatu Sa'adah(2488010008)

INFORMASI & PROFIL DATASET

Dataset House Prices

Dataset terdiri dari: 1.460 baris data, 81 kolom,
80 variabel prediktor , 1 target variable yaitu SalePrice

Struktur Fitur

- OverallQual : kualitas keseluruhan material dan finishing rumah
- GrLivArea : luas area hunian di atas tanah
- GarageCars : kapasitas mobil pada garasi
- GarageArea : luas garasi
- TotalBsmtSF : luas total basement
- 1stFlrSF : luas lantai pertama
- FullBath : jumlah kamar mandi penuh
- YearBuilt : tahun pembangunan rumah
- YearRemodAdd : tahun renovasi rumah
- SalePrice : harga jual rumah (target)

OverallQual merepresentasikan kualitas material dan finishing rumah, sedangkan GrLivArea merupakan luas area hunian di atas tanah.

Alur Pengolahan dan Pemodelan Data

01 Exploratory Data Analysis (EDA)

Menganalisis Struktur dan karakteristik dataset, Distribusi SalePrice, Missing value, Fitur numerik dan kategorikal, Hubungan fitur dengan harga rumah, Korelasi antarvariabel

02 Data Preprocessing

Menangani missing value, Memisahkan fitur dan target, Menghapus Id, Encoding variabel kategorikal, Membagi data menjadi data latih dan data uji, Scaling fitur sesuai kebutuhan

03 Regresi Linear & Evaluasi

Melatih model Linear Regression, Melakukan prediksi SalePrice, Mengevaluasi model menggunakan: MSE, RMSE, R^2 . Menganalisis residual dan actual vs predicted, Alur regresi tersebut sesuai dengan tujuan praktikum regresi pada modul, termasuk training, koefisien, MSE, RMSE, dan R^2 .

EDA: ANALISIS UNIVARIAT SALEPRICE

===== STATISTIK SALEPRICE =====

SalePrice

count 1460.000000

mean 180921.195890

std 79442.502883

min 34900.000000


25% 129975.000000

50% 163000.000000

75% 214000.000000

max 755000.000000

dtype: float64



Distribusi SalePrice menunjukkan rentang harga yang cukup lebar. Sebagian besar rumah berada pada kelompok harga rendah hingga menengah, sementara terdapat beberapa rumah dengan harga sangat tinggi. Hal tersebut menunjukkan adanya variasi harga yang cukup besar dan kemungkinan adanya nilai ekstrem pada rumah dengan karakteristik premium.

EDA: ANALISIS FITUR NUMERIK

FITUR OVERALLQUAL

OverallQual merupakan penilaian kualitas keseluruhan material dan finishing rumah.

Interpretasi

OverallQual menunjukkan hubungan yang sangat kuat dengan SalePrice, dengan korelasi sebesar 0,79.

Hal ini menunjukkan bahwa semakin tinggi kualitas material dan finishing rumah, semakin besar kecenderungan harga jual rumah.

FITUR GRLIVAREA

GrLivArea merupakan luas area hunian di atas tanah.

Interpretasi

GrLivArea memiliki korelasi sebesar 0,71 terhadap SalePrice. Rumah dengan luas area hunian yang lebih besar cenderung memiliki harga jual yang lebih tinggi.



EDA: FITUR DENGAN KORELASI

Berdasarkan hasil korelasi, OverallQual merupakan variabel yang paling kuat hubungannya dengan harga rumah, diikuti oleh luas area hunian (GrLivArea) dan karakteristik garasi serta basement.

	SalePrice
SalePrice	1.000000
OverallQual	0.790982
GrLivArea	0.708624
GarageCars	0.640409
GarageArea	0.623431
TotalBsmtSF	0.613581
1stFlrSF	0.605852
FullBath	0.560664
TotRmsAbvGrd	0.533723
YearBuilt	0.522897
YearRemodAdd	0.507101
GarageYrBlt	0.486362
MasVnrArea	0.477493
Fireplaces	0.466929
BsmtFinSF1	0.386420


EDA: ANALISIS BIVARIAT

1. HUBUNGAN OVERALLQUAL DAN SALEPRICE

Scatter/box plot menunjukkan:

Terdapat kecenderungan peningkatan SalePrice seiring dengan meningkatnya OverallQual.

Rumah dengan kualitas rendah cenderung memiliki harga lebih rendah, sedangkan rumah dengan kualitas tinggi memiliki rentang harga yang lebih tinggi.




2. HUBUNGAN GRLIVAREA DAN SALEPRICE

Terdapat hubungan positif yang cukup kuat.

Semakin besar luas area hunian, harga rumah cenderung meningkat.

Namun, terdapat beberapa titik yang menyimpang dari pola umum sehingga menunjukkan adanya outlier atau rumah dengan karakteristik khusus.



EDA: FITUR GARASI & BASEMENT

GarageCars vs SalePrice

Korelasi GarageCars terhadap SalePrice sebesar 0,64. Rumah dengan kapasitas garasi lebih besar cenderung memiliki harga lebih tinggi.

GarageArea vs SalePrice

GarageArea memiliki korelasi 0,62, menunjukkan bahwa ukuran garasi juga berkaitan cukup kuat dengan harga rumah.


TotalBsmntSF vs SalePrice

Luas basement memiliki korelasi 0,61, sehingga rumah dengan basement yang lebih luas cenderung mempunyai nilai jual lebih tinggi.

Kesimpulan

Selain kualitas dan luas hunian, fasilitas tambahan seperti garasi dan basement juga menjadi indikator penting dalam harga rumah.

MATRIKS KORELASI & HEATMAP



Hasil Analisis

Korelasi paling kuat terhadap SalePrice ditemukan pada:

- OverallQual → 0,79
- GrLivArea → 0,71
- GarageCars → 0,64
- GarageArea → 0,62
- TotalBsmtSF → 0,61

Interpretasi

Heatmap menunjukkan bahwa variabel yang berkaitan dengan kualitas, luas bangunan, dan fasilitas rumah memiliki hubungan positif yang relatif kuat dengan harga jual.

Hasil korelasi ini menjadi dasar dalam memahami fitur yang berpotensi memberikan kontribusi besar terhadap model prediksi.

EDA: ANALISIS MISSING VALUE

Variabel dengan Missing Value Terbesar

Missing value pada dataset tidak selalu berarti data rusak. Pada beberapa variabel, nilai kosong menunjukkan bahwa rumah memang tidak memiliki fasilitas tersebut.

Contohnya:

- PoolQC kosong → tidak memiliki kolam
- FireplaceQu kosong → tidak memiliki fireplace
- beberapa fitur garasi kosong → tidak memiliki garasi

Dokumentasi dataset memang mendefinisikan NA pada beberapa fitur sebagai kondisi tidak adanya fasilitas, misalnya FireplaceQu dan fitur-fitur garage

***	Jumlah Missing	Persentase (%)
PoolQC	1453	99.52
MiscFeature	1406	96.30
Alley	1369	93.77
Fence	1179	80.75
MasVnrType	872	59.73
FireplaceQu	690	47.26
LotFrontage	259	17.74
GarageQual	81	5.55
GarageFinish	81	5.55
GarageType	81	5.55
GarageYrBlt	81	5.55
GarageCond	81	5.55
BsmtFinType2	38	2.60
BsmtExposure	38	2.60
BsmtCond	37	2.53
BsmtQual	37	2.53
BsmtFinType1	37	2.53
MasVnrArea	8	0.55
Electrical	1	0.07

PREPROCESSING DATA

PEMISAHAN FEATURE & TARGET

Feature (X):

Seluruh variabel karakteristik rumah yang digunakan untuk memprediksi harga.

Target (y):

SalePrice

Penghapusan Kolom

Kolom Id dihapus karena hanya berfungsi sebagai identitas rumah dan tidak memberikan informasi karakteristik yang bermakna untuk prediksi harga.

STEP 14 - PISAHKAN TARGET

```
x = df.drop(columns=['SalePrice'])
y = df['SalePrice']

print("Ukuran X:", x.shape)
print("Ukuran y:", y.shape)
```

```
Ukuran X: (1460, 80)
Ukuran y: (1460,)
```

STEP 15 - HAPUS Id

```
x = x.drop(columns=['Id'])

print("Ukuran X setelah Id dihapus:", x.shape)
```

```
Ukuran X setelah Id dihapus: (1460, 79)
```

PREPROCESSING: HANDLING MISSING VALUE

Penanganan Missing Value

- Missing value kategorikal yang menunjukkan ketiadaan fasilitas diberi kategori khusus seperti None.
- Missing value numerik ditangani menggunakan metode imputasi yang sesuai.
- Missing value pada variabel yang benar-benar kosong ditangani menggunakan nilai statistik yang sesuai.

Tujuan

Menghasilkan dataset yang lengkap dan dapat diproses oleh algoritma machine learning tanpa kehilangan makna dari masing-masing variabel.

STEP 17 - HANDLE MISSING VALUE

```
# Salinan data
X_processed = X.copy()

# Kolom kategorikal
cat_cols = X_processed.select_dtypes(
    include=['object']
).columns

# Missing kategori dianggap tidak memiliki fitur
X_processed[cat_cols] = X_processed[cat_cols].fillna('None')

# Kolom numerik diisi dengan median
num_cols = X_processed.select_dtypes(
    include=['int64', 'float64']
).columns

X_processed[num_cols] = X_processed[num_cols].fillna(
    X_processed[num_cols].median()
)

print("Total missing setelah preprocessing:",
      X_processed.isnull().sum().sum())
```

```
*** Total missing setelah preprocessing: 0
```

PREPROCESSING: CATEGORICAL ENCODING

STEP 18 - ONE HOT ENCODING

```
X_encoded = pd.get_dummies(  
    X_processed,  
    drop_first=True,  
    dtype=int  
)  
  
print("Ukuran data setelah encoding:")  
print(X_encoded.shape)  
  
display(X_encoded.head())
```

Ukuran data setelah encoding:
(1460, 260)

	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd	MasVnrArea	BsmtFinSF1	BsmtFinSF2	BsmtUnfSF	TotalBsmtSF	1stFlrSF	2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath	BsmtHalfBath	FullBath	HalfBath	BedroomAbvGr	KitchenAbvGr	TotRmsAbvGrd	Fireplaces	GarageYrBlt	G
0	60	65.0	8450	7	5	2003	2003	196.0	706	0	150	856	856	854	0	1710	1	0	2	1	3	1	8	0	2003.0	
1	20	80.0	9600	6	8	1976	1976	0.0	978	0	284	1262	1262	0	0	1262	0	1	2	0	3	1	6	1	1976.0	
2	60	68.0	11250	7	5	2001	2002	162.0	486	0	434	920	920	866	0	1786	1	0	2	1	3	1	6	1	2001.0	
3	70	60.0	9550	7	5	1915	1970	0.0	216	0	540	756	961	756	0	1717	1	0	1	0	3	1	7	1	1998.0	
4	60	84.0	14260	8	5	2000	2000	350.0	655	0	490	1145	1145	1053	0	2198	1	0	2	1	4	1	9	1	2000.0	

Variabel kategorikal dikonversi menjadi bentuk numerik menggunakan One-Hot Encoding.

Tujuan

Mengubah data kategorikal menjadi representasi numerik sehingga dapat digunakan oleh algoritma Linear Regression, tanpa menganggap bahwa kategori memiliki tingkatan tertentu.

PREPROCESSING: PEMBAGIAN DATA

STEP 19 - TRAIN TEST SPLIT

```
▶ x_train, x_test, y_train, y_test = train_test_split(  
    X_encoded,  
    y,  
    test_size=0.2,  
    random_state=42  
)
```

```
print("X_train:", x_train.shape)  
print("X_test :", x_test.shape)  
print("y_train:", y_train.shape)  
print("y_test :", y_test.shape)
```

```
*** X_train: (1168, 260)  
    X_test : (292, 260)  
    y_train: (1168,)  
    y_test : (292,)
```

Dataset train.csv dibagi menjadi:

80% → Data Training

Digunakan untuk melatih model dan mempelajari hubungan antara karakteristik rumah dengan SalePrice.

20% → Data Testing

Digunakan untuk menguji kemampuan model pada data yang tidak digunakan selama proses training.

Catatan

test.csv Kaggle tidak digunakan untuk evaluasi karena file tersebut tidak memiliki kolom SalePrice.

REGRESI LINEAR: PEMODELAN

```
... Model Linear Regression berhasil dilatih.
```

PELATIHAN MODEL

Model yang digunakan: Multiple Linear Regression

Model mempelajari hubungan antara berbagai karakteristik rumah dengan SalePrice.

Tahapan

- 1.Data hasil preprocessing dimasukkan ke model.
- 2.Model dilatih menggunakan data training.
- 3.Model mempelajari koefisien masing-masing fitur.
- 4.Model digunakan untuk memprediksi harga pada data testing.

REGRESI LINEAR: KOEFISIEN FITUR

Koefisien positif menunjukkan bahwa peningkatan nilai suatu fitur cenderung meningkatkan prediksi SalePrice, dengan asumsi fitur lainnya tetap.

Koefisien negatif menunjukkan kecenderungan penurunan prediksi harga ketika nilai fitur meningkat. intinya kualitas rumah dan ukuran rumah menjadi karakteristik yang paling menonjol dalam hubungan dengan harga jual berdasarkan analisis korelasi awal.

Koefisien negatif

	Fitur	Koefisien
91	Condition2_PosN	-9728.390853
203	KitchenQual_TA	-9801.475676
151	ExterQual_Gd	-10377.709506
152	ExterQual_TA	-10458.851123
225	GarageQual_Gd	-16071.691266
113	RoofMatl_Metal	-26676.953759
224	GarageQual_Fa	-27353.153318
114	RoofMatl_Roll	-28002.857200
236	PoolQC_Fa	-33289.576995
228	GarageQual_TA	-46136.703238
116	RoofMatl_WdShake	-48425.378086
117	RoofMatl_WdShngl	-55349.723644
237	PoolQC_Gd	-55784.694604
115	RoofMatl_Tar&Grv	-83794.647264
111	RoofMatl_CompShg	-120762.612673

Koefisien positif

	Fitur	Koefisien
32	PoolArea	264483.995047
238	PoolQC_None	234806.123370
233	GarageCond_TA	41643.038039
246	MiscFeature_TenC	23080.656862
229	GarageCond_Fa	21469.859473
15	GrLivArea	13910.938186
13	2ndFlrSF	12737.099884
230	GarageCond_Gd	12411.221259
215	GarageType_Attchd	10821.245041
219	GarageType_Detchd	10451.025962
11	TotalBsmtSF	9783.370324
5	YearBuilt	9647.381428
232	GarageCond_Po	9280.428608
3	OverallQual	9258.540143
8	BsmtFinSF1	8232.002866

REGRESI LINEAR: EVALUASI MODEL

Metrik Evaluasi

MSE – Mean Squared Error

Mengukur rata-rata kuadrat kesalahan prediksi.

Semakin kecil nilai MSE, semakin baik model.

RMSE – Root Mean Squared Error

Menunjukkan rata-rata besarnya kesalahan prediksi dalam satuan harga rumah.

R^2 – Coefficient of Determination

Menunjukkan proporsi variasi SalePrice yang dapat dijelaskan oleh model.

	Metrik	Nilai
0	MSE	6.903743e+09
1	RMSE	8.308877e+04
2	R^2	9.994137e-02

```
-- MSE: 6903743265.120189
```

```
-- RMSE: 83088.76738236155
```

```
R2: 0.09994137424672311
```


ACTUAL VS PREDICTED

Analisis Visualisasi

Grafik Actual vs Predicted digunakan untuk membandingkan harga rumah sebenarnya dengan harga yang diprediksi oleh model. Apabila titik-titik prediksi semakin mendekati garis diagonal, maka prediksi model semakin mendekati nilai aktual.

Interpretasi

Model diharapkan dapat mengikuti pola harga aktual, tetapi kemungkinan terdapat penyimpangan terutama pada rumah dengan harga ekstrem karena hubungan antara karakteristik rumah dan harga tidak sepenuhnya linear.



ANALISIS RESIDUAL

Residual = Nilai Aktual - Nilai Prediksi


Interpretasi

Residual digunakan untuk melihat pola kesalahan prediksi model.

Model yang baik diharapkan memiliki residual yang:

- tersebar di sekitar nilai 0,
- tidak membentuk pola tertentu,
- dan memiliki penyebaran yang relatif acak.

Jika residual membentuk pola tertentu, hal tersebut dapat menunjukkan bahwa model Linear Regression belum sepenuhnya menangkap hubungan kompleks pada data harga rumah.



KESIMPULAN

Berdasarkan hasil Exploratory Data Analysis (EDA), variabel yang memiliki hubungan paling kuat dengan harga rumah adalah OverallQual, GrLivArea, GarageCars, GarageArea, dan TotalBsmtSF.

Tahap preprocessing dilakukan dengan menangani missing value, mengubah variabel kategorikal menggunakan One-Hot Encoding, menghapus Id, serta membagi data menjadi data training dan testing.

Selanjutnya, model Multiple Linear Regression digunakan untuk memprediksi SalePrice. Performa model dievaluasi menggunakan MSE, RMSE, dan R^2 serta dianalisis menggunakan grafik Actual vs Predicted dan residual.

Secara keseluruhan, hasil analisis menunjukkan bahwa kualitas, luas bangunan, serta fasilitas rumah merupakan faktor penting dalam menentukan harga jual rumah.

Machine Learning

**SEKIAN
TERIMA KASIH**

