


EDA, PREPROCESSING, DAN IMPLEMENTASI REGRESI

Dataset House Prices

Nama Kelompok: Adam Fadli

Kelompok : 2



DATASET & ALUR PROSES


BARIS
1.460

KOLOM
81

TARGET
SalePrice

Tujuan

Memprediksi harga rumah berdasarkan karakteristik rumah.



1450	1451	90	RL	60.0	9000	Pave	NaN	Reg	Lvl	AllPub	FR2	Gtl	NAmes	Norm	Norm	Duplex	2St
1451	1452	20	RL	78.0	9262	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	Somerst	Norm	Norm	1Fam	1St
1452	1453	180	RM	35.0	3675	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	Edwards	Norm	Norm	TwoHSE	SI
1453	1454	20	RL	90.0	17217	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	Michel	Norm	Norm	1Fam	1St
1454	1455	20	FV	62.0	7500	Pave	Pave	Reg	Lvl	AllPub	Inside	Gtl	Somerst	Norm	Norm	1Fam	1St
1455	1456	60	RL	62.0	7917	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	Gilbert	Norm	Norm	1Fam	2St
1456	1457	20	RL	85.0	13175	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	NAmes	Norm	Norm	1Fam	1St
1457	1458	70	RL	66.0	9042	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	Crawfor	Norm	Norm	1Fam	2St
1458	1459	20	RL	68.0	9717	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	NAmes	Norm	Norm	1Fam	1St
1459	1460	20	RL	75.0	9937	Pave	NaN	Reg	Lvl	AllPub	Inside	Gtl	Edwards	Norm	Norm	1Fam	1St

EDA

Exploratory Data Analysis dilakukan untuk memahami kondisi dataset sebelum digunakan untuk pemodelan.

```
df.head()
df.shape
df.info()
df.describe()
df.isnull().sum()
df.duplicated().sum()
```

YANG DIPERIKSA


- Struktur dan ukuran data
- Tipe data
- Statistik data
- Missing value
- Data duplikat

Masukkan screenshot: hasil df.info() atau df.describe()

HASIL EDA & VISUALISASI


Distribusi SalePrice

Melihat sebaran target




GrLivArea vs SalePrice

Melihat kecenderungan hubungan



Correlation Heatmap

Membandingkan korelasi



INSIGHT

OverallQual memiliki hubungan yang kuat dengan SalePrice. • GrLivArea menunjukkan kecenderungan hubungan positif dengan SalePrice. • Terdapat beberapa missing value yang perlu ditangani pada tahap preprocessing.

PREPROCESSING

Missing Value



Encoding



Pemisahan X dan y



Train/Test Split

```
X = df.drop(columns=['SalePrice'])  
y = df['SalePrice']
```

KETERANGAN

X = fitur / karakteristik rumah
y = target yang diprediksi (SalePrice)

Data kategorikal perlu melalui encoding agar dapat diproses model.

PRINSIP

Preprocessing memastikan data lebih siap, konsisten, dan kompatibel dengan model regresi.

TRAIN TEST SPLIT

100% Data

80% TRAINING

20% TESTING

```
X_train, X_test, y_train, y_test =  
train_test_split(  
    X, y,  
    test_size=0.2,  
    random_state=42  
)
```

FUNGSI

Training data
digunakan untuk melatih model.

Testing data
digunakan untuk menguji model pada data yang
belum digunakan saat training.

IMPLEMENTASI & EVALUASI REGRESI

Linear Regression

```
model = LinearRegression()  
model.fit(X_train, y_train)  
y_pred = model.predict(X_test)
```

Makna metrik

MSE mengukur kesalahan prediksi.

RMSE mengukur rata-rata besarnya kesalahan prediksi.

R^2 mengukur kemampuan model menjelaskan variasi target.

EVALUASI

```
mse = mean_squared_error(y_test, y_pred)  
rmse = np.sqrt(mse)  
r2 = r2_score(y_test, y_pred)
```

HASIL ASLI

MSE: 6903743265.120189

RMSE: 83088.76738236155

R^2 : 0.09994137424672311

Model berhasil melakukan prediksi, tetapi nilai R^2 yang rendah menunjukkan bahwa kemampuan model dalam menjelaskan variasi harga rumah masih terbatas.

KESIMPULAN

Secara keseluruhan, proses EDA dan preprocessing berhasil mempersiapkan dataset untuk pemodelan. Linear Regression dapat digunakan untuk memprediksi harga rumah, namun nilai R^2 sebesar 0,0999 menunjukkan bahwa performa model masih terbatas dalam menjelaskan variasi SalePrice. Oleh karena itu, diperlukan pengembangan lebih lanjut pada preprocessing dan pemilihan fitur untuk meningkatkan performa prediksi.



**TERIMA
KASIH!**